

Rapport d'audit des données

Filderland Agrar GmbH — Région de Stuttgart, 2021-2026

Étapes 1-4 sur 4 : Audit, Data cleaning, Feature engineering et Analyse

Document vivant : ce rapport sera complété au fil des étapes 2 (nettoyage), 3 (feature engineering) et 4 (analyse et recommandations).

Toutes les données sont fictives, générées à des fins pédagogiques.

1. Présentation du fichier

- Fichier source : Filderland_Agrar_Stuttgart_Brut_2021-2026.xlsx
- 2 onglets : « Notes » (documentation du jeu de données) et « Ventes_Brutes » (les données à nettoyer)
- 536 lignes dans l'onglet Ventes_Brutes, dont 2 lignes de légende en pied de fichier (hors données réelles)
- 534 lignes de ventes réelles constituent le périmètre de cet audit
- 10 colonnes brutes, aux noms peu explicites : ID, Datum1, Art, Ort, Kunde_Name_2, Kanal, Menge, Preis, Betrag_2, Stat

2. Les 5 défauts quantifiés

2.1 Doublons

27 lignes sont des doublons stricts (identiques sur toutes les colonnes, y compris l'identifiant) et devront être supprimées lors du nettoyage.

- Doublons stricts détectés : 27 lignes en trop
- Aucun cas de conflit (même ID mais contenu différent) — la suppression sera donc sans ambiguïté

2.2 Valeurs manquantes

178 lignes sur 534 (33 %) comportent au moins une valeur manquante. Détail par colonne :

Colonne	Valeurs manquantes	% des lignes
Ort (district)	20	3,7 %
Kunde_Name_2 (client)	8	1,5 %
Menge (quantité)	41	7,7 %
Preis (prix unitaire)	15	2,8 %
Betrag_2 (montant)	157	29,4 %

Le montant (Betrag_2) est la colonne la plus souvent vide — sans conséquence si on le recalcule systématiquement (voir section 3).

2.3 Formats incohérents

Dates (colonne Datum1) — 5 formats différents cohabitent sur les 534 lignes :

Format rencontré	Nombre de lignes
JJ.MM.AAAA	113
Date native Excel (datetime)	113
JJ/MM/AAAA	110
AAAA/MM/JJ	106
JJ-MM-AAAA	92

Nombres saisis en texte avec virgule décimale (ex. « 118,16 » au lieu de 118.16) :

- Menge (quantité) : 54 valeurs concernées
- Preis (prix unitaire) : 46 valeurs concernées

Casse et orthographe incohérentes sur les champs catégoriels — bien plus de variantes qu'une simple différence de casse :

Colonne	Val. distinctes	Exemples de variantes
Art (produit)	32	Weizen / WEIZEN / weizen ; Aepfel / Apfel / Apples / äpfel ; Wein / Trollinger / Wein(Trollinger) ; Filderkraut / Filder Kraut / Kraut / Weisskohl
Ort (district)	30	Stuttgart / STUTTGART / stuttgart / S ; Böblingen / Boeblingen / BB ; Göppingen / Goeppingen / GP
Kanal (canal)	16	Export / EXPORT / export ; Grosshandel / großhandel / GROSSHANDEL ; Coop, Markt (hors les 4 canaux officiels)
Stat (statut)	6	Geliefert / GELIEFERT / geliefert ; Storniert / STORNIERT

Point d'attention pour le nettoyage : au-delà de la casse, certaines variantes sont des synonymes ou traductions (Apples = pommes en anglais, Ble = blé en français, Weisskohl = chou blanc) qui nécessiteront une table de correspondance, pas seulement une mise en majuscule/minuscule.

2.4 Valeurs aberrantes

Type d'anomalie	Nombre de lignes
Quantités négatives	13
Quantités anormalement élevées (facteur ×1000 suspecté, ex. 89 800)	16
Prix unitaire à zéro	11
Prix unitaire anormalement élevé (facteur ×100 suspecté, ex. 762)	2
Dates hors période plausible 2021-2026 (années 1900 ou 2099 rencontrées)	15

2.5 Colonnes mal nommées

Les 10 colonnes brutes portent des noms abrégés, en allemand, sans unité ni convention claire. Aucune ne peut rester telle quelle. Mapping de renommage retenu (documenté dans le CLAUDE.md du projet) :

Brut	Renommé
Datum1	Date_Vente
Art	Produit
Ort	District
Menge	Quantite_kg_ou_t
Preis	Prix_Unitaire_EUR
Betrag_2	Montant_EUR
Stat	Statut

3. Point de contrôle : fiabilité du montant

Sur les 353 lignes où quantité, prix et montant sont tous renseignés et non aberrants, le montant (Betrag_2) est égal à Quantité × Prix dans 100 % des cas (353/353).

Conclusion retenue pour l'étape 2 : plutôt que de conserver la colonne Montant brute (29 % de valeurs manquantes), on la recalculera systématiquement comme Quantité × Prix une fois ces deux colonnes nettoyées. Cela règle mécaniquement le problème des montants manquants.

4. Synthèse

Défaut	Ampleur mesurée
1. Doublons	27 lignes strictes à supprimer
2. Valeurs manquantes	178 lignes concernées (33 %), colonne Montant la plus touchée
3. Formats incohérents	5 formats de date, 100 nombres texte à virgule, 84 variantes de casse/orthographe cumulées
4. Valeurs aberrantes	13 quantités négatives, 16 ×1000, 11 prix à zéro, 2 ×100, 15 dates hors période
5. Colonnes mal nommées	10 colonnes sur 10 à renommer

5. Étape 2 — Data cleaning : décisions et résultats

Fichier livré : Filderland_Agrar_Stuttgart_Nettoye_2021-2026.xlsx (le fichier brut n'a jamais été modifié).
Traitements appliqués, dans l'ordre :

5.1 Suppression des doublons et des dates non exploitables

- 27 doublons stricts supprimés (aucun conflit de contenu à arbitrer)
- 14 lignes exclues pour date hors période plausible (1900 ou 2099) : aucune méthode fiable pour reconstituer la vraie date, donc exclusion plutôt qu'invention d'une valeur

5.2 Corrections numériques (valeur d'origine conservée, erreur mécanique corrigée)

Correction appliquée	Lignes concernées
Quantité négative -> valeur absolue (erreur de signe)	13

Correction appliquée	Lignes concernées
Quantité > 1000 -> divisée par 1000 (erreur d'unité)	15
Prix aberrant -> divisé par 100 (erreur d'unité)	6
Prix à 0 -> recalculé depuis Montant brut / Quantité	9

Montant recalculé systématiquement ($\text{Quantité} \times \text{Prix}$) pour les 493 lignes conservées, plutôt que de garder la colonne Montant brute.

Révision méthodologique (détectée à l'étape 4) : le premier seuil retenu pour repérer les prix $\times 100$ était un seuil fixe (« prix > 100 € »), qui ne détectait que 2 lignes. Il ratait les erreurs $\times 100$ sur des produits dont le prix normal est inférieur à 1 € (ex. 0,54 € saisi comme 54 €, sous la barre des 100 €). Le seuil a été remplacé par une comparaison à la médiane de chaque produit (prix > 10 fois la médiane du produit), qui détecte 6 lignes au total. Les chiffres ci-dessous intègrent cette correction.

5.3 Valeurs manquantes non récupérables : laissées vides, jamais devinées

Conformément à la règle du projet de ne jamais inventer une donnée absente du fichier source, les valeurs manquantes qui ne pouvaient pas être recalculées à partir d'autres colonnes de la même ligne ont été laissées vides plutôt qu'estimées (ex. par une moyenne). Elles restent identifiables via la colonne Remarque_Nettoyage.

Champ	Lignes laissées vides
Quantité (aucune donnée pour la recalculer)	37
Prix (aucune donnée pour le recalculer)	12
Prix (était à 0, non récupérable)	1
District (non renseigné à la source)	20
Client (non renseigné à la source)	8

Conséquence : le Montant est calculable pour 443 des 493 lignes (90 %) ; les 50 lignes restantes (10 %) n'ont pas de montant faute de quantité ou de prix fiable — elles restent dans le fichier pour les analyses qui n'en ont pas besoin (ex. comptage par produit ou par date).

5.4 Harmonisation des libellés (produit, district, canal, statut)

Toutes les variantes de casse et d'orthographe ont été ramenées aux libellés officiels. Certains rapprochements sont des traductions ou synonymes identifiés avec un niveau de confiance élevé — documentés ici pour transparence :

Colonne	Rapprochement effectué	Justification
District	S, BB, ES, LB, GP -> Stuttgart, Böblingen, Esslingen, Ludwigsburg, Göppingen	Ce sont les codes officiels d'immatriculation allemands (Kfz-Kennzeichen) de ces villes/arrondissements — correspondance certaine, pas une supposition
Produit	Apples -> Äpfel ; Ble -> Weizen ; Asparagus -> Spargel	Traduction directe anglais/français -> allemand
Produit	Trollinger, Wein(Trollinger) -> Wein	Trollinger est un cépage rouge cultivé dans la région, vendu ici comme catégorie « Wein »

Colonne	Rapprochement effectué	Justification
Produit	Kraut, Weisskohl -> Filderkraut	Seul légume-chou du catalogue produit ; rapprochement plausible mais moins certain que les autres — à valider métier
Canal	Coop -> Genossenschaft ; Markt -> Wochenmarkt	Coop = coopérative (= Genossenschaft) ; Markt = marché (= Wochenmarkt)

5.5 Bilan des lignes

Étape	Lignes
Lignes de ventes réelles auditées	534
– doublons stricts supprimés	-27
– dates hors période exclues	-14
= Lignes dans la base nettoyée	493
dont lignes ayant subi une correction numérique	43
dont lignes avec au moins une valeur restée manquante	78

6. Étape 3 — Feature engineering : résultats

Fichier livré : Filderland_Agrar_Stuttgart_Enrichi_2021-2026.xlsx, construit à partir de la base nettoyée (493 lignes). 5 onglets : les ventes enrichies ligne à ligne, et 4 tables d'indicateurs agrégés.

6.1 Dimensions temporelles et famille de produit

- Année, Mois (+ nom du mois), Trimestre (T1-T4) extraits de Date_Vente
- Saison météorologique : Printemps (mars-mai), Été (juin-août), Automne (sept-nov), Hiver (déc-fév)
- Famille de produit : Légumes (Filderkraut, Spargel, Kartoffeln), Fruits (Äpfel), Viticulture (Wein), Céréales (Weizen) — 100 % des lignes rattachées, aucune sans famille
- Statut converti en deux indicateurs booléens : Est_Livre / Est_Annule

Taux d'annulation mesuré sur la base nettoyée : 9 commandes annulées sur 493 (1,8 %).

6.2 Indicateurs agrégés (calculés sur les commandes livrées uniquement)

Les commandes annulées (Storniert) sont exclues de ces indicateurs : elles ne représentent pas un chiffre d'affaires réel. CA total livré sur la période : 13 243,89 €.

Par produit

Produit	CA (€)	Volume (kg/t)	Prix moyen pondéré (€)	Part de marché
Wein	4 096,48	956,14	4,28	30,9 %
Spargel	3 584,85	506,96	7,07	27,1 %
Äpfel	2 101,67	3 197,88	0,66	15,9 %
Kartoffeln	1 627,95	3 812,79	0,43	12,3 %

Produit	CA (€)	Volume (kg/t)	Prix moyen pondéré (€)	Part de marché
Weizen	1 164,69	5 160,97	0,23	8,8 %
Filderkraut	668,25	1 592,00	0,42	5,0 %

Par famille de produit

Famille	CA (€)	Part de marché
Légumes	5 881,05	44,4 %
Viticulture	4 096,48	30,9 %
Fruits	2 101,67	15,9 %
Céréales	1 164,69	8,8 %

Par district

District	CA (€)	Part de marché
Stuttgart	2 720,05	20,5 %
Rems-Murr-Kreis	2 244,34	16,9 %
Böblingen	2 229,75	16,8 %
Esslingen	1 976,74	14,9 %
Göppingen	1 801,81	13,6 %
Ludwigsburg	1 719,49	13,0 %

Par canal de vente

Canal	CA (€)	Part de marché
Grosshandel	3 604,98	27,2 %
Export	3 526,09	26,6 %
Genossenschaft	3 360,42	25,4 %
Wochenmarkt	2 752,40	20,8 %

Ces chiffres intègrent la révision méthodologique décrite en section 5.2 (détection des prix aberrants par comparaison à la médiane du produit plutôt que par seuil fixe), qui a fait baisser le CA total livré de 26 090 € à 13 244 € — la version précédente était faussée par 4 lignes de prix $\times 100$ non détectées.

7. Étape 4 — Analyse : réponses aux 7 catégories de questions métier

Livrables : la présentation PDF exécutive (points 1-6, pour l'équipe dirigeante), le tableau de bord interactif (mêmes points, graphiques variés), et cette section détaillée (les 7 points, y compris la qualité des données à usage plus opérationnel).

Révision méthodologique (2e correction trouvée à l'étape 4) : le champ Client (Kunde_Name_2) n'avait pas été nettoyé des espaces parasites en début/fin de chaîne lors de l'étape 2 — seuls Produit, District, Canal et Statut l'avaient été. Résultat : 24 « clients » distincts apparaissaient au lieu de 12 réels (70 valeurs sur 526 concernées côté fichier brut), ce qui répartissait artificiellement le CA de chaque client entre deux variantes de son nom. Corrigé

rétroactivement dans la base nettoyée et enrichie ; sans impact sur les doublons déjà supprimés (vérifié : 0 doublon supplémentaire détecté après correction).

7.1 Les 3 insights chiffrés retenus

- Performance globale : CAGR de +4,1 % entre 2021 et 2026, mais avec un décrochage de -13,9 % en 2025 (vs 2024) suivi d'un rebond de +26,1 % en 2026 — une croissance moyenne qui masque une forte irrégularité
- Portefeuille produits : Wein et Spargel génèrent 58,0 % du chiffre d'affaires pour seulement 9,6 % du volume vendu — la valeur ajoutée est concentrée sur un très petit volume
- Clients : après correction du défaut ci-dessus, 12 clients réels (et non 24) se partagent le CA de façon équilibrée (5,6 % à 9,7 % chacun) — l'enjeu est l'étroitesse de la base client, pas une concentration de risque

7.2 Réponses par catégorie

Catégorie	Constat principal
1. Performance globale	CAGR +4,1 % (2021-2026) ; taux d'annulation stable à 1,8 %
2. Portefeuille produits	Wein + Spargel = 58 % du CA pour 9,6 % du volume ; Kartoffeln en repli (-13,6 % de CA entre 2021 et 2026), Äpfel en forte hausse (+68,8 %)
3. Districts	Stuttgart en tête (20,5 % du CA) ; pas de concentration de risque (top 2 = 37,4 %) ; écart de valorisation notable : Böblingen réalise 1,03 €/kg vendu contre 0,76 €/kg à Göppingen (potentiel de montée en gamme à mix produit comparable)
4. Clients & canaux	12 clients réels, répartition équilibrée (5,6 % à 9,7 % du CA chacun, aucune dépendance excessive) ; Grosshandel (27,2 %) et Export (26,6 %) en tête des canaux ; Export en repli en 2025 puis fort rebond en 2026 (+23,8 % sur 2021-2026)
5. Prix & rentabilité	Prix stables par produit une fois les erreurs de saisie corrigées (écart-type de 18 % à 29 % de la moyenne selon le produit), mais écarts significatifs par district pour un même produit (ex. Wein : -19,7 % à Göppingen, +14,9 % à Böblingen, n≥10 ventes)
6. Saisonnalité	Spargel et Kartoffeln culminent au printemps, Wein et Weizen en été, Filderkraut et Äpfel en hiver — cycle stable sur 2021-2026
7. Qualité des données	Coût de la non-qualité estimé à 1 525,79 € de CA non mesurable (50 lignes sur 493, soit 10 %, sans montant calculable faute de quantité ou de prix fiable)

7.3 Recommandations

- Renforcer Wein et Spargel, produits à forte valorisation mais volumes encore modestes
- Élargir la base client (12 comptes actifs) plutôt que gérer un risque de concentration — la priorité est l'acquisition de nouveaux clients
- Étudier l'écart de valorisation entre districts (Böblingen 1,03 €/kg vs Göppingen 0,76 €/kg) et les écarts de prix par district pour un même produit
- Investiguer le creux de CA de 2025 avant de considérer le rebond 2026 comme acquis
- Suivre le repli de Kartoffeln (-13,6 %) pour distinguer une cause structurelle d'un artefact de données
- Fiabiliser la saisie de la quantité et du prix à la source pour réduire le coût de la non-qualité (≈1 526 €)

8. Limites

- Toutes les données sont fictives, générées à des fins pédagogiques — aucune décision réelle ne doit s'appuyer sur ces chiffres
- 78 lignes (16 %) conservent une valeur manquante non récupérable, ce qui peut légèrement sous-estimer les indicateurs de volume/CA
- Le rapprochement « Kraut »/« Weiskohl » -> Filderkraut reste une hypothèse plausible mais non certaine, à valider avec un expert métier avant tout usage réel

Livrables finaux du module : base nettoyée (Filderland_Agrar_Stuttgart_Nettoye_2021-2026.xlsx), base enrichie (Filderland_Agrar_Stuttgart_Enrichi_2021-2026.xlsx), présentation exécutive PDF (Presentation_Recommandations_Filderland_Agrar.pdf, points 1-6), tableau de bord interactif (points 1-6, graphiques variés) et ce rapport d'audit (les 7 points, document de référence méthodologique).